

# Homework 1

---

## Statistische modellen en data analyse

**Andreas Put – Ma1 Computerwetenschappen**

**27/04/2011**

[Type the abstract of the document here. The abstract is typically a short summary of the contents of the document. Type the abstract of the document here. The abstract is typically a short summary of the contents of the document.]

## Vraag 1

### deel 1

$$F_X(x) = \begin{cases} 1 - (1-p)^{\lfloor x \rfloor} & \text{Als } x \geq 1 \\ 0 & \text{Elders} \end{cases}$$

De dichtheidsfunctie  $f_X(x)$  van  $F_X(x)$  kan berekend worden door  $F_X$  af te leiden naar  $x$

$$\begin{aligned} f_X(x) &= \frac{\partial F_X(x)}{\partial x} \\ &= -\ln(1-p) (1-p)^{\lfloor x \rfloor} \end{aligned}$$

Via de formule  $\text{MLE} = \arg\max_{\theta \in \Theta} \prod_{i=1}^n f_{\theta}(x_i)$  kunnen we de maximum likelihood estimator vinden

$$\text{MLE}_p = \arg\max \left[ \prod_{i=1}^n (-\ln(1-p)(1-p)^{\lfloor x_i \rfloor}) \right]$$

## Vraag 2

### Deel 1

De onderstaande formules worden veelvuldig gebruikt voor deze vraag:

$$E[X_2 | X_1 = x_1] = \mu_2 + \Sigma_{21} \Sigma_{11}^{-1} (x_1 - \mu_1) \quad (1) \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$$

$$\text{Cov}[X_2 | X_1 = x_1] = \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \quad (2) \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

We beginnen bij  $Y|Z$

$Y|Z$  is normaal verdeeld:  $Y|Z \sim N(1+Z, 1)$  (3)

Vullen we  $x_1 = \mu_1$  in in (1) dan bekommen we

$E[X_2 | X_1 = \mu_1] = \mu_2 = 1+Z$  (3). Omdat  $Z = x_1 = \mu_1 = 0 \rightarrow \mu_2 = 1$

Vullen we  $x_1 = 2$  in en daar  $\Sigma_{11} = 1$  bekommen we

$E[X_2 | X_1 = 2] = 1+Z = 3 = 1 + \Sigma_{21}(2-0) \rightarrow \Sigma_{21} = 1 = \Sigma_{12}$

$\Sigma_{22}$  verkrijgen we via (2)

$\text{Cov}[X_2 | X_1 = 0] = 1 = \Sigma_{22} - 1/1 * 1 \rightarrow \Sigma_{22} = 2$

$$\Rightarrow [Z \ Y]^T \sim \left( \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \right)$$

Vervolgens analyseren we  $X|Y,Z$

Vullen we  $x_1 = \mu_1 = [0 \ 1]^T$  in in (1) dan bekommen we  $E[X_2|X_1 = \mu_1] = \mu_2 = 1 - Y = 0$

Vullen we  $x_1 = [1, 1]^T$  in en daar  $\Sigma_{11} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}$  is, bekommen we

$$E[X_2|X_1 = x_1] = 1 - Y = 0 = \Sigma_{21} \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \Sigma_{21} \begin{bmatrix} 2 \\ -1 \end{bmatrix} = 0 \quad (4)$$

$$\text{Met } x_1 = [0 \ 0]^T \text{ bekommen we } E[X_2|X_1 = x_1] = 1 - Y = 1 = \Sigma_{21} \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \Sigma_{21} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = 1 \quad (5)$$

Uit (4) en (5) kunnen we  $\Sigma_{21}$  halen  $\rightarrow \Sigma_{21} = [1 \ 2] = \Sigma_{12}^T$

$\Sigma_{22}$  verkrijgen we via (2)

$$\text{Cov}[X_2|X_1 = \mu_1] = 1 = \Sigma_{22} - \Sigma_{12} \Sigma_{11}^{-1} \Sigma_{12}^T \rightarrow \Sigma_{22} = 3$$

$$\Rightarrow [Z \ Y \ X]^T \sim \left( \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{bmatrix} \right) \rightarrow [X \ Y \ Z]^T \sim \left( \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 & 2 & 1 \\ 2 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} \right)$$

## Y|X,Z

Hiervoor is de verdeling van  $[X,Z]^T$  nodig:

$$[X \ Z]^T \sim \left( \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix} \right) \quad X, Z, Y \sim \left( \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 & 1 & 2 \\ 1 & 1 & 1 \\ 2 & 1 & 2 \end{bmatrix} \right)$$

$$E[Y|X, Z = \mu] = 1 + [2 \ 1] \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} X - 0 \\ Z - 0 \end{bmatrix} = \frac{1}{2}(Z + X)$$

$$\text{Cov}[Y|X, Z = \mu] = 2 - [2 \ 1] \begin{bmatrix} 3 & 1 \\ 1 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 2 \\ 1 \end{bmatrix} = 2 - 1.5 = 0.5$$

$$Y|X, Z \sim (\frac{1}{2}(Z + X), 0.5)$$

## Deel 2

De verdeling van  $[U \ V]^T$  waar  $U = 1 + Z$  en  $V = 1 - Y$ :

$U = 1 + Z \rightarrow \mu_u = 1 + \mu_z$ ;  $S_u = S_z \rightarrow U \sim (1, 1)$  - Er verandert niets aan de variantie na optelling van een constante.

$V = 1 - Y \rightarrow \mu_v = 1 - \mu_y$ ;  $S_v = S_y \rightarrow V \sim (0, 2)$

$$\mu_{U,V} = [1 \ 0]$$

$$\Sigma_{U,V} = \begin{bmatrix} \Sigma_Z & \Sigma_{ZY} \\ \Sigma_{ZY} & \Sigma_Y \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}$$

## Deel 3

Omdat de variantie van U gelijk is aan die van Z, en de variantie van V is gelijk aan de variantie van Y, is de covariantiematrix van  $[U, Y]$  gelijk aan die van  $[U, V]$

$$E(Y|U = 2) = \mu_y + \Sigma_{21} \Sigma_{11}^{-1} (2 - \mu_u) \quad \begin{bmatrix} U \\ Y \end{bmatrix} \sim \left( \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \right)$$

$$= 1 + 1/1 * (2 - 1) = 2$$

### Vraag 3

Gegeven de steekproef met verdeling

$$N_3 \sim \begin{pmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \end{pmatrix} \Sigma$$

De hypothese  $H_0 : \mu_1 = \mu_2 = \mu_3$  v.s.  $H_1 : \mu_i \neq \mu_j$  kan als volgt geëvalueerd worden.

We stellen een alternatieve hypothese op:

$$H_0' : \mu = \begin{bmatrix} \mu_1 - \mu_1 \\ \mu_2 - \mu_1 \\ \mu_3 - \mu_1 \end{bmatrix} = 0 \text{ v.s. } H_1' : \mu \neq 0$$

Via de  $T^2$ -test van Hotelling kan deze hypothese aangenomen of verworpen worden.

Omdat deze test affien invariant is, zal de volgende hypothese

$$H_{Y0} : A\mu = 0 \text{ v.s. } H_{Y1} : A\mu \neq 0 \quad (\det(A) \neq 0)$$

hetzelfde resultaat opleveren. De kritieke waarde van de  $T^2$  test zal immers hetzelfde zijn als bij de originele hypothese test.

Een geschikte matrix A hiervoor is:  $A1 = \begin{bmatrix} 0 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & -1 & 1 \end{bmatrix}$   $(\det(A1) = 1)$

$$A1 * \mu \text{ levert als resultaat: } \begin{bmatrix} \mu_1 - \mu_2 \\ 0 = (\mu_2 - \mu_2) \\ \mu_3 - \mu_2 \end{bmatrix}$$

Een andere matrix die we kunnen opstellen is:  $A2 = \begin{bmatrix} 0 & 0 & -1 \\ 0 & 1 & -1 \\ 1 & 0 & 0 \end{bmatrix}$   $\det(A2) = 1$

$$A2 * \mu \text{ levert als resultaat: } \begin{bmatrix} \mu_1 - \mu_3 \\ \mu_2 - \mu_3 \\ 0 = (\mu_3 - \mu_3) \end{bmatrix}$$

Door het toepassen van de transformaties door de matrix  $A_i$  wordt getest of  $\mu_1 = \mu_2 = \mu_3$ .

### Vraag 4

#### Deel 1

De R code voor deze oefening is te vinden in bijlage ....

Omdat we (ongecorreleerde) gepaarde steekproeven behandelen, is het aantal genomen samples gelijk aan  $n = 10$

De hypothesetest

$$H_0 : \mu_1 = \mu_2 \text{ v.s. } H_1 : \mu_1 \neq \mu_2$$

kan worden opgelost door eerst de twee gepaarde steekproeven samen te voegen. De kenmerken van de resulterende steekproef worden dan:

$$X_p = X_1 - X_2 \quad \text{en} \quad S_p = \frac{n \cdot S_1 + n \cdot S_2}{2 \cdot n}$$

Met deze samengestelde gemiddelde en covariantiematrix kan een nieuwe hypothese worden opgesteld:

$$H'_0 : \mu_p = 0 \text{ v.s. } H_1 : \mu_1 \neq 0$$

De test of de hypothese geldt of niet wordt uitgevoerd door middel van de Hotelling test voor gepaarde steekproeven.

$$T^2 = n * x_p^T * S_p^{-1} * x_p$$

En zo kan de F waarde berekend worden:

$$F = \frac{(n-p) * T^2}{p * (n-1)}$$

Als deze waarde groter is dan de kritische waarde  $F_{0.95,2,8}$  zal de hypothese verworpen worden.

In dit geval geldt :  $F = 7.901235$ ,  $F_{0.95,2,8} = 4.45897$

(Alle tussenberekeningen en uitkomsten kunnen verkregen worden door het R bestand uit te voeren)

De hypotheektest leert ons dat  $\mu_p \neq 0$ , en dus  $\mu_1 \neq \mu_2$ , maar het zegt niets over welke elementen hiervoor verantwoordelijk zijn.

## Deel 2

Om dit te onderzoeken gebruiken we betrouwbaarheidsintervallen voor de verschillende elementen van  $x_p$ . Wanneer 0 niet in dit betrouwbaarheidsinterval ligt, zal de nulhypothese verworpen worden. Omdat  $X_p = X_1 - X_2$  zal als 0 niet in het betrouwbaarheidsinterval van  $X_{pi}$  ligt ook  $X_{1i} \neq X_{2i}$  zijn.

Het betrouwbaarheidsinterval voor  $X_p(i)$  wordt via de volgende formule berekend:

$$[X_p(i) \pm t_{n-1, 1-\alpha/2} \sqrt{Sp(i, i)/n}]$$

Voor  $H_0 : \mu_{11} = \mu_{21}$  v.s.  $H_1 : \mu_{11} \neq \mu_{21}$  bekomen we het volgende betrouwbaarheidsinterval  
[0.2477406    3.7522594]

Omdat 0 niet in dit interval ligt, kunnen we de nulhypothese verwerpen.

Voor  $H_0 : \mu_{12} = \mu_{22}$  v.s.  $H_1 : \mu_{12} \neq \mu_{22}$  bekomen we het volgende betrouwbaarheidsinterval

$$[-1.752259 \quad 1.752259]$$

0 ligt in dit interval, en we nemen de hypothese dus aan.



#### #####EXERCISE 4#####

##### ###Part 1###

```
matrix(c(3,1),ncol = 1)->x1
matrix(c(1,1),ncol = 1)->x2
matrix(c(4,-1,-1,2),nrow = 2, ncol=2, byrow=TRUE)->s1
matrix(c(2,-2,-2,4),nrow = 2, ncol=2, byrow=TRUE)->s2
#Merge the covariance matrices and means
sp <- (9*s1+9*s2)/(18);sp
xp <- x1-x2;xp
```

#T<sup>2</sup> Hotelling test

#calculate T<sup>2</sup>

```
t2<- 10*t(xp)%*(solve(sp))%*(xp);t2
```

#Calculate F value

```
f<-(10-2)*t2/((10-1)*2);f #f <- (n1+n2-k-1)*t2/((n1+n2-2)*k)
```

#Calculate critical value

```
crit<-qf(.95,2,8)
```

#rejection region

```
c(crit,Inf) ## if f in rejection region ==> Reject!
```

##### ###Part 2###

#Confidence interval for x(1,1)

#If 0 lies in the CI, we accept the hypothesis, otherwise reject.

```
t <- qt(.975,9);t
```

```
cil1 <- xp[1] - t*sqrt((2*sp[1,1])/10)
```

```
cih1 <- xp[1] + t*sqrt((2*sp[1,1])/10)
```

```
c(cil1,cih1)
```

##### ###Part 3###

#Confidence interval for x(2,1)

#If 0 lies in the CI, we accept the hypothesis, otherwise reject.

```
cil2 <- xp[2] - t*sqrt((2*sp[2,2])/10)
```

```
cih2 <- xp[2] + t*sqrt((2*sp[2,2])/10)
```

```
c(cil2,cih2)
```